

BI-Projekt: Globale CO₂-Emissionen & Wirtschaftskraft

Table of Contents

Slide 1: Idee & Forschungsfragen	2
Thema	2
Forschungsfragen (OLAP-Operationen)	2
Slide 2: Hauptdatenquellen	2
Datenquelle 1: Our World in Data - CO ₂ Dataset	2
Datenquelle 2: World Bank GDP per capita (Update-Quelle)	2
Data-Cleansing-Schritte in Python (Pandas)	3
Slide 3: Enrichment-Dateien	4
Enrichment 1: Länder-Kontinent Mapping (ISO 3166)	4
Data-Cleansing	4
Geodaten (Optional für Leaflet/Folium Plot)	4
Slide 4: Datenwürfel & Dimensionen	5
Architektur (Star-Schema via Merges)	5
Dimensionen & Faktentabelle	5
Extras: Binning & Calculated Values	6
Slide 5: Ridiculous Dimensions	7
"Ridiculous" Dimension 1: Alphabetische Ländergruppe	7
"Ridiculous" Dimension 2: Nationaltiere	7
Slide 6: Report (Python Visualizations)	8
Slide 6a: Seriöser Report	8
Slide 6b: Ridiculous Report & Extra Stuff	10
Slide 7: Diskussion & Beantwortung	12
F1 - Slice (Geo-Verteilung 2022)	12
F2 - Dice (Europäischer Energie-Mix 2000-2022)	12
F3 - Drill-Down (Wirtschaftskraft vs. Emissionen in Europa)	12
Ridiculous Finding	12

Slide 1: Idee & Forschungsfragen

Thema

Dieses BI-Projekt analysiert den logischen Zusammenhang zwischen globalen **CO₂-Emissionen**, der **Wirtschaftskraft (BIP)** und der **Bevölkerungsgröße** auf Länder- und Kontinentebene. Die Datenverarbeitung (ETL, Star-Schema Generierung) wurde als "Code-First"-Ansatz in Python (Pandas) implementiert.

Forschungsfragen (OLAP-Operationen)

Nr.	Forschungsfrage	OLAP-Operation
F1	Wie verteilen sich die Pro-Kopf-CO ₂ -Emissionen weltweit im Jahr 2022 – welche Länder emittieren besonders viel?	Slice - Zeitdimension auf ein Jahr fixiert
F2	Wie hoch sind die Gesamt-CO ₂ -Emissionen in Europa im Zeitraum 2000–2022 , und wie unterscheidet sich der Anteil von Kohle-, Öl- und Gasverbrennung?	Dice - Filterung auf geographische Region Kontinent sowie Zeitraum gleichzeitig
F3	Drill-Down von Kontinentebene auf Länderebene : Welche europäischen Staaten treiben die Gesamtemissionen Europas an, und wie ist dies im Verhältnis zur ihrer Wirtschaftskraft (BIP)?	Drill-Down - Aggregationsebene von Europa auf Länder herabbrechen

Slide 2: Hauptdatenquellen

Datenquelle 1: Our World in Data - CO₂ Dataset

- **Typ:** Incremental (jährlich um ein neues Kalenderjahr ergänzt)
- **Inhalt:** Detaillierte Aufschlüsselung globaler CO₂-Emissionen, Energieträger, BIP, Bevölkerung etc. pro Land (Zeile = Land pro Jahr). Ca. 79 Spalten.
- **Quelle:** <https://raw.githubusercontent.com/owid/co2-data/master/owid-co2-data.csv>

Datenquelle 2: World Bank GDP per capita (Update-Quelle)

- **Typ:** Update (Vergangene historische BIP-Werte werden bei Datenänderungen geupdatet)
- **Inhalt:** Jährliches GDP (BIP) als Wide-Format (eine Spalte pro Jahr). Dient im Modell als Update-Quelle.

- Quelle: <https://api.worldbank.org/v2/en/indicator/NY.GDP.PCAP.CD?downloadformat=csv>

Data-Cleansing-Schritte in Python (Pandas)

Schritt	Python Implementierung / Beschreibung
1. Spaltenauswahl	<code>df[['iso_code', 'year', 'co2', ...]]</code> - Unnötige Spalten entfernen.
2. Zeilen-Filterung	<code>df.dropna(subset=['iso_code'])</code> um aggregierte Regionen herauszufiltern.
3. Zeit-Filter	<code>df[(df['year'] >= 1990) & (df['year'] <= 2023)]</code> - Beschneidung auf Relevanz.
4. Null-Werte	<code>df[col].fillna(0)</code> für spezifische Energieträgerspalten.
5. Umbenennungen	<code>df.rename(columns={'co2_per_capita': 'CO2_pro_Kopf_t'})</code> für bessere Beschreibungen.
6. World Bank (Update Quelle)	Wide-Format CSV der WorldBank: via <code>pd.melt()</code> in Long-Format umgewandelt und als <code>BIP_USD_WB</code> direkt per Left-Join (<code>iso_code + year</code>) an die Faktentabelle gemerged.
7. Energieträger Entpivotieren	Die Spalten <code>coal_co2</code> , <code>oil_co2</code> , <code>gas_co2</code> via <code>pd.melt()</code> umwandeln, um in Folge eine separate <code>DIM_Energietraeger</code> zu verknüpfen.

Slide 3: Enrichment-Dateien

Enrichment 1: Länder-Kontinent Mapping (ISO 3166)

- **Idee:** Der OWID-Datensatz besitzt von sich aus keine geographischen Kontinent-Hierarchien. Um Forschungsfrage 3 (Kontinent Drill-Down) auszuführen und geographische Karten (Geo-Plots) zu bedienen, müssen die ISO-Codes mit Kontinenten gemerged werden.
- **Inhalt:** Land, ISO-Alpha-3 Code, Region, Sub-Region
- **Quelle:** <https://raw.githubusercontent.com/luke/ISO-3166-Countries-with-Regional-Codes/master/all/all.csv>

Data-Cleansing

- Entfernen aller Spalten bis auf Name, Alpha-3 (Join-Keys), Region und Sub-Region.
- Umbenennung zu sprechenden Bezeichnern.

Geodaten (Optional für Leaflet/Folium Plot)

In der Datenquelle `owid_co2_data.csv` existiert bereits eine Spalte `iso_code`. Diese geographische Information wird beim späteren Erstellen des Dashboards Python-Packages wie *Plotly* automatisch verwendet, um geographische Heatmaps auf der Erdkugel zu visualisieren.

Slide 4: Datenwürfel & Dimensionen

Architektur (Star-Schema via Merges)

Obwohl in Python das BI-Datenmodell oft zu einem großen, einheitlichen Flat-DataFrame verarbeitet wird, basiert die logische Konstruktion des ETL-Prozesses explizit auf einem Star-Schema. Die Python-Pipeline verarbeitet Rohdaten und splittet sie in die jeweiligen Dims/Facts auf, die beim Plotting in ein zentrales Star-Modell geknüpft werden:




Figure 1. Star-Schema (PlantUML ER-Diagramm)

Dimensionen & Faktentabelle

Tabelle	Beschreibung
FACT_Emissionen	Kern der Daten. Enthält FKs, Population, CO2-Absolute- und Pro-Kopf-Werte sowie die ge-mergten World-Bank BIP Updates (BIP_USD_WB). Entpivotiert nach Energieträgern (Kohle, Öl, Gas).
DIM_Land	ISO-Hierarchien. Länderkürzel verlinkt zu Regionen & Kontinenten.
DIM_Zeit	Zeitdimensionen. Per Python generiert. Bündelt Jahre zu Dekaden ("2000er") und Klimavertrags-Epochen ("Post-Kyoto", "Post-Paris").
DIM_Energietraeger	Extraktion der Entpivotierten Energieträgerspalten in eine Dimension Kohle, Öl, Gas.

Extras: Binning & Calculated Values

Beide Berechnungen wurden dynamisch während des ETL-Laufs via Pandas erzeugt:

1. Binning: Bevoelkerungs_Klasse Aufspaltung der stetigen Skala an Population in vier Kategorien durch `pd.cut()`:

- **Klein:** unter 1 Million Einwohner
- **Mittel:** 1 - 10 Millionen
- **Groß:** 10 - 100 Millionen
- **Gigantisch:** über 100 Millionen

2. Calculated Value: CO2_Intensitaet Spiegelt die Effizienz der CO2-Erzeugung zur Wirtschaftskraft wider.

- DAX/Pandas Äquivalent: $\text{Gesamt_CO2_Mt} / (\text{BIP_USD} / 1.000.000)$
- *Szenariodiskussion:* Vergleicht wie viel CO2 beim generieren von einer Millionen USD BIP pro Staat ausgestoßen wird.

Slide 5: Ridiculous Dimensions

Zusätzlich zu den Kernanforderungen beinhaltet das Datenmodell zwei vollkommen irrsinnige Dimensionen, um die Flexibilität der ETL-Pipeline zu demonstrieren.

"Ridiculous" Dimension 1: Alphabetische Ländergruppe

(Generiert aus bestehenden Basisdaten, keine externe File)

Länder werden basierend auf ihrem Anfangsbuchstaben gruppiert, um auszuwerten, ob der Anfangsbuchstabe eines Landes eine "Scheinkorrelation" zum CO₂-Ausstoß hat.

- **A-F:** z.B. Austria, Australia, France
- **G-L:** z.B. Germany, Italy, Japan
- **M-R:** z.B. Mexico, Russia
- **S-Z:** z.B. Sweden, USA (United States), Switzerland

"Ridiculous" Dimension 2: Nationaltiere

(via zusätzlicher Enrichment CSV-Datei [national_animals.csv](#))

Jedem Land (ISO-Code) wird sein offizielles/inoffizielles Nationaltier (z.B. Adler, Känguru, Gallischer Hahn) zugewiesen, um zu evaluieren, ob Länder mit Raubtieren als Maskottchen eventuell mehr Fossilbrennstoffe verbrauchen.

Slide 6: Report (Python Visualizations)

Das Dashboarding und Plotting wurde mittels **Plotly**, **Seaborn** und **Matplotlib** direkt auf Basis der verknüpften Star-Schema CSV-Exportdateien via Code generiert.

Slide 6a: Seriöser Report

Weltweiter CO₂-Ausstoß pro Kopf (2022)




Figure 2. Visualisierung 1: CO₂ pro Kopf nach Land (Slice 2022 / Geographisch)




Figure 3. Visualisierung 2: Energieträgermix in Europa (Dice 2000-2022)




Figure 4. Visualisierung 3: BIP vs. Gesamtemissionen in Europa (Drill-Down auf Länder)

Slide 6b: Ridiculous Report & Extra Stuff




Figure 5. Visualisierung 4: Welches Nationaltier stößt am meisten CO₂ aus? (Ridiculous Plot)




Figure 6. Visualisierung 5: Korrelations-Heatmap (Geiler Scheiß / Extra Point)

Begründung Extra-Stuff: Um dem analytischen Kern von Business Intelligence gerecht zu werden, wurde klassisches Machine Learning/Data Science Tooling (Korrelationsmatrizen) eingebaut. Es beweist statistisch, dass z.B. ein starkes BIP in massivster Korrelation zum CO₂-Ausstoß steht (Echte Korrelation).

Slide 7: Diskussion & Beantwortung

F1 - Slice (Geo-Verteilung 2022)

Ergebnis: Saudi-Arabien, die vereinigten Arabischen Emirate und weite Teile Nordamerikas/Osteuropas dominieren die globale Karte des *Pro-Kopf-CO₂-Ausstoßes*. *Interpretation:* Länder mit enorm hohen Erträgen durch Ölförderung weisen auch bevölkerungsbereinigt extrem schlechte (rote) Emissions-Werte auf, während Westeuropa und Südamerika deutlich moderater agieren.

F2 - Dice (Europäischer Energie-Mix 2000-2022)

Ergebnis: Insgesamt zeigt sich bei der Auswertung im Balkendiagramm ein klarer, historischer Abwärtstrend der Gesamtemissionen Europas seit dem Jahr 2000. *Interpretation:* Besonders die Emissionen aus Kohle wurden extrem zurückgefahren (Kohleausstieg), während Gas eine leichte, aber konstante Basisversorgung übernommen hat.

F3 - Drill-Down (Wirtschaftskraft vs. Emissionen in Europa)

Ergebnis: Der Log-Log-Scatterplot deckt auf, dass Länder wie Deutschland oder UK beim CO₂-Ausstoß und BIP im ersten Quadranten ganz oben aufscheinen. *Interpretation:* Wirtschaftskraft und Emissionen wachsen grob linear (auf der logarithmischen Achse). Auffällig ist jedoch, dass z.B. Frankreich bei fast identischem BIP wie UK/Deutschland merklich weniger CO₂ emittiert – vermutlich zurückzuführen auf starke historische Nuklearenergieanteile (welche im Datensatz keinen Fossil-Fußabdruck erzeugen).

Ridiculous Finding

Ergebnis: Länder, welche einen großen **Bären** (Russischer Bär) oder große **Vögel** (Adler / USA) als Maskottchen haben, weisen historisch den absolut katastrophalsten CO₂-Schnitt auf. Länder mit Springböcken oder Jaguaren sind am umweltfreundlichsten unterwegs.