

# BI-Projekt: Globale CO<sub>2</sub>-Emissionen & Wirtschaftskraft

## Table of Contents

|                                                                  |   |
|------------------------------------------------------------------|---|
| Slide 1: Idee & Forschungsfragen .....                           | 2 |
| Thema .....                                                      | 2 |
| Forschungsfragen (OLAP-Operationen) .....                        | 2 |
| Slide 2: Hauptdatenquellen .....                                 | 2 |
| Datenquelle 1: Our World in Data - CO <sub>2</sub> Dataset ..... | 2 |
| Datenquelle 2: World Bank GDP per capita (Update-Quelle) .....   | 2 |
| Data-Cleansing-Schritte in Python (Pandas) .....                 | 3 |
| Slide 3: Enrichment-Dateien .....                                | 4 |
| Enrichment 1: Länder-Kontinent Mapping (ISO 3166) .....          | 4 |
| Data-Cleansing .....                                             | 4 |
| Geodaten (Optional für Leaflet/Folium Plot) .....                | 4 |
| Slide 4: Datenwürfel & Dimensionen .....                         | 5 |
| Architektur (Star-Schema via Merges) .....                       | 5 |
| Dimensionen & Faktentabelle .....                                | 5 |
| Extras: Binning & Calculated Values .....                        | 6 |

# Slide 1: Idee & Forschungsfragen

## Thema

Dieses BI-Projekt analysiert den logischen Zusammenhang zwischen globalen **CO<sub>2</sub>-Emissionen**, der **Wirtschaftskraft (BIP)** und der **Bevölkerungsgröße** auf Länder- und Kontinentebene. Die Datenverarbeitung (ETL, Star-Schema Generierung) wurde als "Code-First"-Ansatz in Python (Pandas) implementiert.

## Forschungsfragen (OLAP-Operationen)

| Nr. | Forschungsfrage                                                                                                                                                                                     | OLAP-Operation                                                                         |
|-----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------|
| F1  | Wie verteilen sich die Pro-Kopf-CO <sub>2</sub> -Emissionen weltweit <b>im Jahr 2022</b> – welche Länder emittieren besonders viel?                                                                 | <b>Slice</b> - Zeitdimension auf ein Jahr fixiert                                      |
| F2  | Wie hoch sind die Gesamt-CO <sub>2</sub> -Emissionen in <b>Europa</b> im Zeitraum <b>2000–2022</b> , und wie unterscheidet sich der Anteil von Kohle-, Öl- und Gasverbrennung?                      | <b>Dice</b> - Filterung auf geographische Region Kontinent sowie Zeitraum gleichzeitig |
| F3  | Drill-Down von <b>Kontinentebene</b> auf <b>Länderebene</b> : Welche europäischen Staaten treiben die Gesamtemissionen Europas an, und wie ist dies im Verhältnis zur ihrer Wirtschaftskraft (BIP)? | <b>Drill-Down</b> - Aggregationsebene von Europa auf Länder herabbrechen               |

# Slide 2: Hauptdatenquellen

## Datenquelle 1: Our World in Data - CO<sub>2</sub> Dataset

- **Typ:** Incremental (jährlich um ein neues Kalenderjahr ergänzt)
- **Inhalt:** Detaillierte Aufschlüsselung globaler CO<sub>2</sub>-Emissionen, Energieträger, BIP, Bevölkerung etc. pro Land (Zeile = Land pro Jahr). Ca. 79 Spalten.
- **Quelle:** <https://raw.githubusercontent.com/owid/co2-data/master/owid-co2-data.csv>

## Datenquelle 2: World Bank GDP per capita (Update-Quelle)

- **Typ:** Update (Vergangene historische BIP-Werte werden bei Datenänderungen geupdatet)
- **Inhalt:** Jährliches GDP (BIP) als Wide-Format (eine Spalte pro Jahr). Dient im Modell als Update-Quelle.

- Quelle: <https://api.worldbank.org/v2/en/indicator/NY.GDP.PCAP.CD?downloadformat=csv>

## Data-Cleansing-Schritte in Python (Pandas)

| Schritt                        | Python Implementierung / Beschreibung                                                                                                                                                                     |
|--------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1. Spaltenauswahl              | <code>df[['iso_code', 'year', 'co2', ...]]</code> - Unnötige Spalten entfernen.                                                                                                                           |
| 2. Zeilen-Filterung            | <code>df.dropna(subset=['iso_code'])</code> um aggregierte Regionen herauszufiltern.                                                                                                                      |
| 3. Zeit-Filter                 | <code>df[(df['year'] &gt;= 1990) &amp; (df['year'] &lt;= 2023)]</code> - Beschneidung auf Relevanz.                                                                                                       |
| 4. Null-Werte                  | <code>df[col].fillna(0)</code> für spezifische Energieträgerspalten.                                                                                                                                      |
| 5. Umbenennungen               | <code>df.rename(columns={'co2_per_capita': 'CP2_pro_Kopf_t'})</code> für bessere Beschreibungen.                                                                                                          |
| 6. World Bank (Update Quelle)  | Wide-Format CSV der WorldBank: via <code>pd.melt()</code> in Long-Format umgewandelt und als <code>BIP_USD_WB</code> direkt per Left-Join ( <code>iso_code + year</code> ) an die Faktentabelle gemerged. |
| 7. Energieträger Entpivotieren | Die Spalten <code>coal_co2</code> , <code>oil_co2</code> , <code>gas_co2</code> via <code>pd.melt()</code> umwandeln, um in Folge eine separate <code>DIM_Energietraeger</code> zu verknüpfen.            |

# Slide 3: Enrichment-Dateien

## Enrichment 1: Länder-Kontinent Mapping (ISO 3166)

- **Idee:** Der OWID-Datensatz besitzt von sich aus keine geographischen Kontinent-Hierarchien. Um Forschungsfrage 3 (Kontinent Drill-Down) auszuführen und geographische Karten (Geo-Plots) zu bedienen, müssen die ISO-Codes mit Kontinenten gemerged werden.
- **Inhalt:** Land, ISO-Alpha-3 Code, Region, Sub-Region
- **Quelle:** <https://raw.githubusercontent.com/luke/ISO-3166-Countries-with-Regional-Codes/master/all/all.csv>

### Data-Cleansing

- Entfernen aller Spalten bis auf Name, Alpha-3 (Join-Keys), Region und Sub-Region.
- Umbenennung zu sprechenden Bezeichnern.

## Geodaten (Optional für Leaflet/Folium Plot)

In der Datenquelle `owid_co2_data.csv` existiert bereits eine Spalte `iso_code`. Diese geographische Information wird beim späteren Erstellen des Dashboards Python-Packages wie *Plotly* automatisch verwendet, um geographische Heatmaps auf der Erdkugel zu visualisieren.

# Slide 4: Datenwürfel & Dimensionen

## Architektur (Star-Schema via Merges)

Obwohl in Python das BI-Datenmodell oft zu einem großen, einheitlichen Flat-DataFrame verarbeitet wird, basiert die logische Konstruktion des ETL-Prozesses explizit auf einem Star-Schema. Die Python-Pipeline verarbeitet Rohdaten und splittet sie in die jeweiligen Dims/Facts auf, die beim Plotting in ein zentrales Star-Modell geknüpft werden:




Figure 1. Star-Schema (PlantUML ER-Diagramm)

## Dimensionen & Faktentabelle

| Tabelle                | Beschreibung                                                                                                                                                                                    |
|------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>FACT_Emissionen</b> | Kern der Daten. Enthält FKs, Population, CO2-Absolute- und Pro-Kopf-Werte sowie die ge-mergten World-Bank BIP Updates ( <b>BIP_USD_WB</b> ). Entpivotiert nach Energieträgern (Kohle, Öl, Gas). |
| <b>DIM_Land</b>        | ISO-Hierarchien. Länderkürzel verlinkt zu Regionen & Kontinenten.                                                                                                                               |
| <b>DIM_Zeit</b>        | Zeitdimensionen. Per Python generiert. Bündelt Jahre zu Dekaden ("2000er") und Klimavertrags-Epochen ("Post-Kyoto", "Post-Paris").                                                              |

| Tabelle            | Beschreibung                                                                                 |
|--------------------|----------------------------------------------------------------------------------------------|
| DIM_Energietraeger | Extraktion der Entpivotierten Energieträgerspalten in eine Dimension <b>Kohle, Öl, Gas</b> . |

## Extras: Binning & Calculated Values

Beide Berechnungen wurden dynamisch während des ETL-Laufs via Pandas erzeugt:

**1. Binning: Bevoelkerungs\_Klasse** Aufspaltung der stetigen Skala an Population in vier Kategorien durch `pd.cut()`:

- **Klein:** unter 1 Million Einwohner
- **Mittel:** 1 - 10 Millionen
- **Groß:** 10 - 100 Millionen
- **Gigantisch:** über 100 Millionen

**2. Calculated Value: CO2\_Intensitaet** Spiegelt die Effizienz der CO2-Erzeugung zur Wirtschaftskraft wider.

- DAX/Pandas Äquivalent:  $\text{Gesamt\_CO2\_Mt} / (\text{BIP\_USD} / 1.000.000)$
- *Szenariodiskussion:* Vergleicht wie viel CO2 beim generieren von einer Millionen USD BIP pro Staat ausgestoßen wird.